PROJETO DE APLICAÇÃO | ARTIGO CIENTÍFICO

Predição da busca por tratamento de saúde mental entre profissionais de tecnologia: comparação de modelos organizacionais e ampliados

Daniel Fontoura

Instituto de Computação – Universidade Federal Fluminense

Introdução ao Aprendizado de Máquina para Saúde | 2026.2

Resumo

Este estudo investiga se características e percepções do ambiente de trabalho de profissionais de tecnologia estão associadas à classificação retrospectiva da busca autorrelatada por tratamento de saúde mental. Foram analisadas 1.259 respostas da *Mental Health in Tech Survey* de 2014, organizada pela Open Sourcing Mental Illness. Dois conjuntos de preditores foram comparados: (A) 18 variáveis organizacionais e de percepção do trabalho; e (B) as mesmas variáveis acrescidas de idade, gênero agrupado, histórico familiar e interferência percebida da saúde mental no trabalho. Foram treinados regressão logística, árvore de decisão e Random Forest com pré-processamento integrado ao ajuste, validação cruzada estratificada de cinco partições no treinamento e teste independente de 252 registros. O modelo organizacional selecionado obteve AUROC de 0,698 e F1 de 0,661; o ampliado alcançou AUROC de 0,898 e F1 de 0,842. Contudo, a análise de ablação sem `work_interfere` reduziu a AUROC do modelo ampliado de regressão logística para 0,758. A ausência dessa resposta quase sempre coincidiu com não ter buscado tratamento, indicando importante efeito de informação condicional e possível atalho preditivo. Os resultados sugerem sinal associativo nas respostas organizacionais, mas não permitem inferir causalidade, realizar diagnóstico, antecipar busca futura ou justificar decisões individuais de recursos humanos.

Palavras-chave: aprendizado de máquina; saúde mental; trabalho em tecnologia; busca por tratamento; classificação supervisionada.

1 Introdução

A saúde mental no ambiente profissional envolve dimensões clínicas, sociais e organizacionais. Estigma, condições de suporte e percepções sobre a disposição para falar de sofrimento psicológico podem influenciar como trabalhadores expressam necessidades e acessam cuidados. Uma revisão sistemática sobre divulgação de problemas de saúde mental no trabalho identificou temas recorrentes relacionados ao estigma, ao contexto organizacional e à identidade profissional (MCGRATH et al., 2023). Entretanto, a divulgação de um problema no trabalho e a busca por tratamento são comportamentos distintos, e resultados sobre um deles não podem ser automaticamente transferidos ao outro.

A Open Sourcing Mental Illness (OSMI) divulgou respostas da pesquisa *Mental Health in Tech Survey* de 2014 para documentar experiências de profissionais do setor tecnológico com saúde mental e práticas do ambiente de trabalho (Open Sourcing Mental Illness, 2014;

Open Sourcing Mental Illness, 2026). Os dados incluem informações sobre benefícios, suporte, possibilidade de afastamento, receios de consequências e histórico autorrelatado de procura de tratamento. Tal disponibilidade permite investigar padrões de classificação supervisionada, mas impõe cautela por se tratar de questionário voluntário, transversal e sem confirmação clínica do desfecho.

A pergunta deste estudo é: *em que medida características e percepções organizacionais permitem discriminar, entre os respondentes da pesquisa, aqueles que relatam já ter buscado tratamento para uma condição de saúde mental?* Como objetivo secundário, investigamos o quanto atributos pessoais e relacionados à condição mental elevam o desempenho, em comparação com o conjunto estritamente organizacional. Esta comparação é importante porque usar um preditor associado diretamente ao histórico de sofrimento pode produzir excelente métrica sem responder à pergunta sobre o ambiente de trabalho.

O estudo contribui com um protocolo reprodutível, que evita ajustar transformações antes da divisão dos dados, compara três algoritmos, mede incerteza da AUROC e realiza ablação de uma variável condicional especialmente informativa. A organização dos métodos e dos resultados busca seguir recomendações de relato transparente de modelos preditivos, como o TRIPOD+AI (COLLINS et al., 2024), sem caracterizar o presente exercício como modelo clínico validado.

2 Trabalhos relacionados

2.1 Levantamento e seleção da literatura

Foi realizada leitura narrativa direcionada de fontes sobre o levantamento OSMI, saúde mental no trabalho e práticas de desenvolvimento e avaliação de modelos. Não se trata de revisão sistemática e não houve estratégia exaustiva de busca com estimativa de cobertura da literatura. O levantamento priorizou fontes primárias para caracterização do dataset e revisões pertinentes à interpretação ética e organizacional do fenômeno (Open Sourcing Mental Illness, 2014; MCGRATH et al., 2023; TOTH et al., 2023).

2.2 Abordagens existentes e comparação crítica

A revisão de McGrath et al. (2023) sintetiza estudos sobre divulgação de problemas mentais no trabalho e destaca fatores como suporte, estigma e contexto da comunicação. Seu desfecho é divulgação, e não uso de tratamento; portanto, oferece fundamentação temática, mas não um parâmetro de AUROC diretamente comparável ao presente estudo. Já Toth et al. (2023) revisam evidências sobre intervenções para reduzir estigma relacionado à saúde mental em ambientes profissionais. Essa literatura ressalta a pertinência de intervenções e políticas coletivas, mas não autoriza inferir que uma variável associada no survey seja causa ou mecanismo de intervenção eficaz.

Do ponto de vista computacional, a comparação de regressão logística, árvores de decisão e florestas aleatórias permite estabelecer um contraste entre interpretabilidade e flexibilidade não linear (PEDREGOSA et al., 2011; BREIMAN, 2001). A interpretação correta das curvas ROC demanda separar capacidade discriminativa de probabilidade calibrada e de acurácia em um limiar específico (FAWCETT, 2006). A importância por permutação, empregada neste trabalho, fornece diagnóstico associativo de atributos, mas não estimativas de efeito causal.

2.3 Lacuna e posicionamento

O objetivo não é demonstrar uma nova arquitetura de aprendizado, nem afirmar generalização populacional. A lacuna prática deste projeto é separar explicitamente a informação organizacional daquela potencialmente relacionada ao próprio histórico de tratamento, para verificar quanto da melhora aparente de desempenho decorre de uma característica autorrelatada condicional e potencialmente posterior ao desfecho.

3 Materiais e métodos

3.1 Desenho do estudo e definição da tarefa

Trata-se de análise secundária observacional e transversal de dados públicos, com tarefa de classificação binária supervisionada. A unidade de observação é a resposta de um participante, não um prontuário ou uma internação. A variável alvo `treatment` responde à pergunta *"Have you sought treatment for a mental health condition?"*; mapeamos `Yes`=1 e `No`=0 (Open Sourcing Mental Illness, 2014). A classificação representa histórico informado no momento da pesquisa. Como os atributos do trabalho e a procura de tratamento foram observados no mesmo questionário, a ordenação temporal não é conhecida.

3.2 Conjunto de dados e caracterização da amostra

O arquivo `survey.csv` contém 1.259 respostas e 27 colunas. O alvo apresenta 637 respostas positivas (50,6%) e 622 negativas (49,4%). A pesquisa contempla múltiplos países, com predomínio dos Estados Unidos (751 respostas). Não se realizou amostragem probabilística para este estudo, nem foram aplicados critérios de exclusão de respondentes na análise preditiva.

A idade contém oito valores fora da faixa adulta plausível predefinida de 18 a 90 anos; foram substituídos por ausentes, preservando as 1.259 linhas. O campo `Gender` inclui 49 formas textuais diferentes, que foram agregadas conservadoramente em masculino, feminino e outra resposta/ambígua, sem inferir identidade nas categorias incertas. A falta de resposta de `work_interfere` alcança 264 casos, o que merece análise independente devido à natureza condicional da pergunta. `comments`, `state` e `Timestamp` não foram usados como atributos. A coluna `Country` foi mantida apenas para caracterização exploratória de subgrupos.

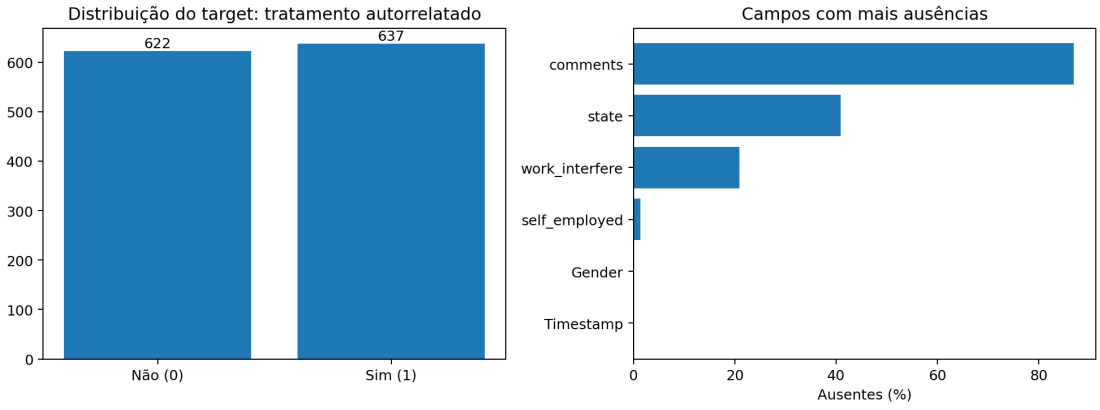


Figura 1: Distribuição de `treatment` e padrões de ausência na base original.

Fonte: elaboração própria com dados da OSMI 2014.

3.3 Conjuntos de atributos e preparação

O conjunto A (organizacional) possui 18 variáveis: autoemprego, número de funcionários, trabalho remoto, tipo de empresa, benefícios, conhecimento de opções de atendimento, programa de bem-estar, recursos de apoio, anonimato, percepção de licença, consequências percebidas para saúde mental e física, disposição para falar com colegas e supervisores, disposição para discutir saúde em entrevistas, percepção de valorização da saúde mental e observação de consequências negativas. Elas abrangem tanto características declaradas das empresas como *percepções individuais do ambiente*; não devem ser confundidas com indicadores objetivos auditados de políticas de RH.

O conjunto B acrescenta ao A quatro atributos: idade, gênero agrupado, histórico familiar e interferência percebida de condição mental no trabalho (`work_interfere`). A última pergunta só é respondível de forma significativa por quem considera possuir tal condição. Para verificar o papel dessa variável, foi feita ablação excluindo apenas `work_interfere`, mantendo as demais entradas do conjunto B.

Todas as transformações fazem parte de um *Pipeline* do *scikit-learn* (PEDREGOSA et al., 2011). A idade inválida é codificada como ausente e imputada com mediana ajustada no conjunto de treinamento do fold, seguida de padronização. Atributos categóricos recebem uma categoria explícita de não informado e codificação *One-Hot*; categorias desconhecidas no teste são ignoradas. A ausência não foi substituída globalmente por moda antes da divisão dos dados, preservando a informação de não resposta.

3.4 Formalização matemática e algoritmos

Dado um vetor de atributos $\mathbf{x}_i$ e o rótulo $y_i \in \{0,1\}$, estimamos $\hat{p}_i = P(y_i = 1 \mid \mathbf{x}_i)$ e classificamos $\hat{y}_i = \mathbb{1}[\hat{p}_i \geq 0{,}5]$. Na regressão logística, a probabilidade é modelada por:

$$\hat{p}_i = \frac{1}{1 + \exp\left[-\left(\beta_0 + \boldsymbol{\beta}^\top \mathbf{x}_i\right)\right]}. \tag{1}$$

O treinamento utiliza regularização controlada pelo hiperparâmetro C. Para a árvore de decisão, partições são construídas pela minimização da impureza nos nós; a Random Forest agrega previsões de múltiplas árvores ajustadas a amostras e seleções de atributos aleatórias (BREIMAN, 2001). Como referência ingênua, foi treinado um *DummyClassifier* que atribui a todos a proporção positiva observada no treinamento; sua AUROC é 0,5.

3.5 Validação, hiperparâmetros e prevenção de vazamento

Os dados foram divididos uma única vez em treinamento (80%, $n = 1.007$, sendo 509 positivos) e teste (20%, $n = 252$, sendo 128 positivos), estratificados por alvo, com semente 42. Exclusivamente no treino, empregou-se validação cruzada estratificada com cinco folds e busca em grade por AUROC. Para regressão logística, $C \in \{0{,}1; 1; 10\}$; para a árvore, profundidade $\in \{3, 5, 8\}$ e mínimo de cinco amostras por folha; para a floresta, profundidade $\in \{6, 12, \text{ilimitada}\}$ com 180 árvores e mínimo de duas amostras por folha. O pré-processamento foi reestimado dentro de cada fold. A seleção do modelo representativo de cada experimento foi determinada pela AUROC média da validação cruzada, e não pelo desempenho de teste.

O teste, mantido reservado durante escolha de parâmetros, serviu à avaliação final. As métricas incluem AUROC, área sob a curva precisão–revocação (AUPRC), acurácia, precisão,

sensibilidade (*recall*) e F1. A sensibilidade e o F1 são calculados como

$$\text{Recall} = \frac{VP}{VP + FN}, \qquad F1 = \frac{2PR}{P + R}, \tag{2}$$

com VP e FN denotando verdadeiros positivos e falsos negativos, e P e R representando precisão e recall. Intervalos percentílicos exploratórios de 95% para AUROC e para a diferença entre experimentos foram calculados com 1.000 reamostragens *bootstrap* das observações de teste; a comparação da diferença é pareada. As curvas de aprendizado foram geradas com dados de treinamento via validação cruzada, sem reutilizar o teste para ajustar hiperparâmetros.

3.6 Reprodutibilidade e aspectos éticos

As bibliotecas empregadas incluem Python, pandas, NumPy, Matplotlib e scikit-learn. O repositório disponibiliza código, *notebook*, sementes, hiperparâmetros, figura e tabelas agregadas. A cópia local do CSV não é versionada por padrão: o campo livre `comments` pode conter relatos sensíveis. O exercício não acessa essas respostas textuais e não é adequado a triagem de candidatos, vigilância de empregados ou classificação clínica individual. As recomendações TRIPOD+AI são utilizadas como referência de transparência, não como alegação de conformidade integral ou validação para uso em saúde (COLLINS et al., 2024).

4 Resultados

4.1 Caracterização e comparação do desempenho

Nenhuma observação foi removida do experimento; oito idades foram imputadas após invalidar valores impossíveis. Os modelos de ambos os conjuntos utilizam o mesmo particionamento. A Tabela 1 apresenta resultados do teste reservado.

Tabela 1: Desempenho dos algoritmos no conjunto de teste ($n = 252$).

Grupo	Algoritmo	AUROC	AUPRC	Acurácia	Recall	F1
A	Regressão logística	0,698	0,731	0,663	0,648	0,661
A	Árvore de decisão	0,671	0,642	0,639	0,492	0,581
A	Random Forest	0,708	0,735	0,651	0,602	0,636
B	Regressão logística	0,898	0,885	0,837	0,852	0,842
B	Árvore de decisão	0,863	0,799	0,829	0,938	0,848
B	Random Forest	0,883	0,857	0,798	0,828	0,806

Fonte: elaboração própria com base na OSMI 2014. Limiar 0,5; seleção por AUROC na validação cruzada.

No conjunto A, a regressão logística obteve AUROC 0,698 (IC95% 0,629–0,763), F1 0,661 e sensibilidade 0,648. No conjunto B, a regressão logística obteve AUROC 0,898 (IC95% 0,858–0,933), F1 0,842 e sensibilidade 0,852. A diferença de AUROC B–A foi de 0,200 (IC95% bootstrap pareado 0,134–0,263). Embora a Random Forest tenha atingido AUROC ligeiramente maior no teste do conjunto A, a regressão logística foi escolhida com base no critério predefinido de validação cruzada, evitando selecionar retrospectivamente por resultado de teste.

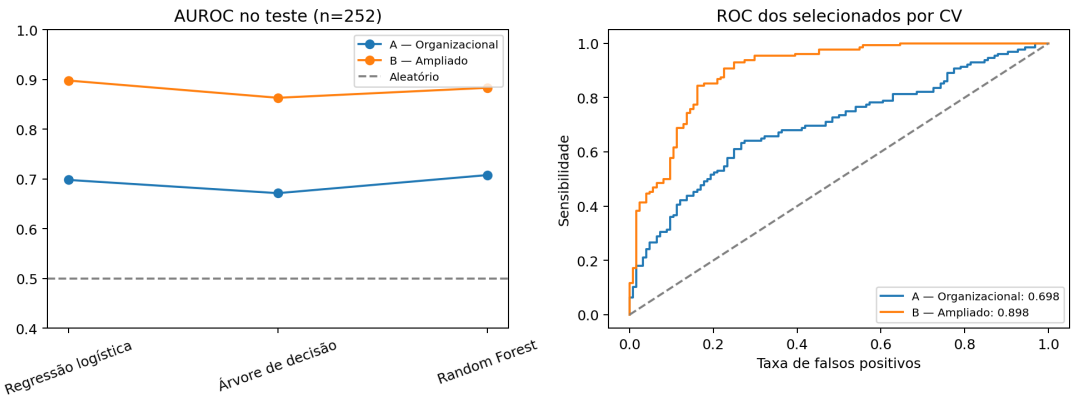


Figura 2: AUROC por algoritmo e curvas ROC dos modelos selecionados na validação cruzada.

Fonte: elaboração própria; desempenho no conjunto reservado de teste.

4.2 Análise de erros e ablação

A matriz de confusão do conjunto A apresentou 83 verdadeiros positivos, 45 falsos negativos, 40 falsos positivos e 84 verdadeiros negativos. Para o B, houve 109 verdadeiros positivos, 19 falsos negativos, 22 falsos positivos e 102 verdadeiros negativos, no limiar fixo de 0,5. Esse ganho não constitui evidência de que características organizacionais tenham maior capacidade de indicar necessidade clínica de tratamento.

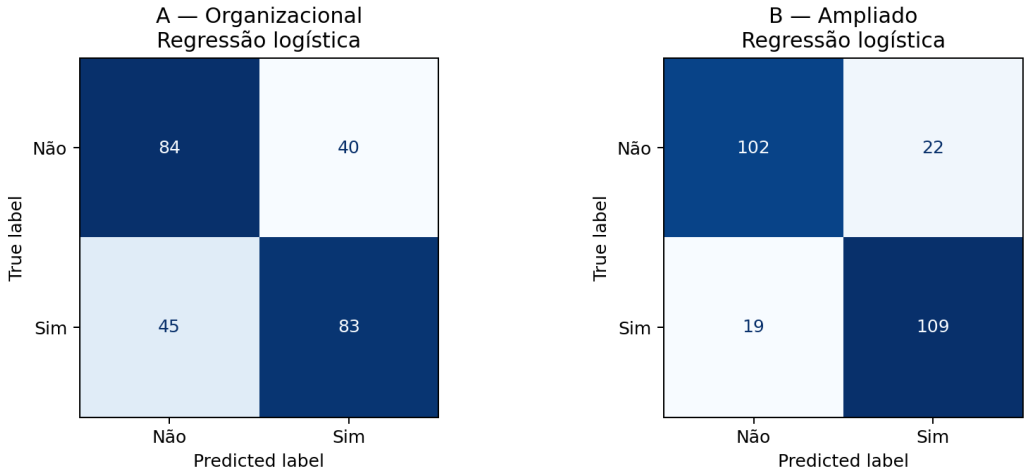


Figura 3: Matrizes de confusão dos modelos selecionados (teste reservado).

Fonte: elaboração própria.

O atributo `work_interfere` apresenta um padrão de não resposta especialmente relevante: entre os 264 registros ausentes, 260 informaram `treatment=No` e apenas quatro informaram `treatment=Yes`. Quando se exclui essa única variável do conjunto ampliado, a regressão logística apresenta AUROC 0,758 no teste, em vez de 0,898. A redução de aproximadamente 0,139 ponto indica que parte expressiva do desempenho ampliado dependia de uma pergunta condicional, cuja ausência por si só quase identifica a classe negativa. Isso recomenda interpretar a melhora como informação associativa próxima ao desfecho e não como solução superior para a pergunta organizacional.

4.3 Curvas de aprendizado e importância por permutação

As curvas de aprendizado da Figura 4 representam AUROC de treinamento e validação em função da quantidade de exemplos disponíveis para ajuste. Elas não representam épocas de rede neural, pois os modelos comparados não foram redes treinadas por épocas. A análise de permutação da Figura 5 indica, no conjunto A, relevância exploratória de conhecimento das opções de atendimento (`care_options`) e benefícios; no B, `work_interfere` passa a dominar a importância. A importância foi avaliada após o ajuste sobre o teste e não deve orientar nova seleção de atributos sem novo conjunto de validação.

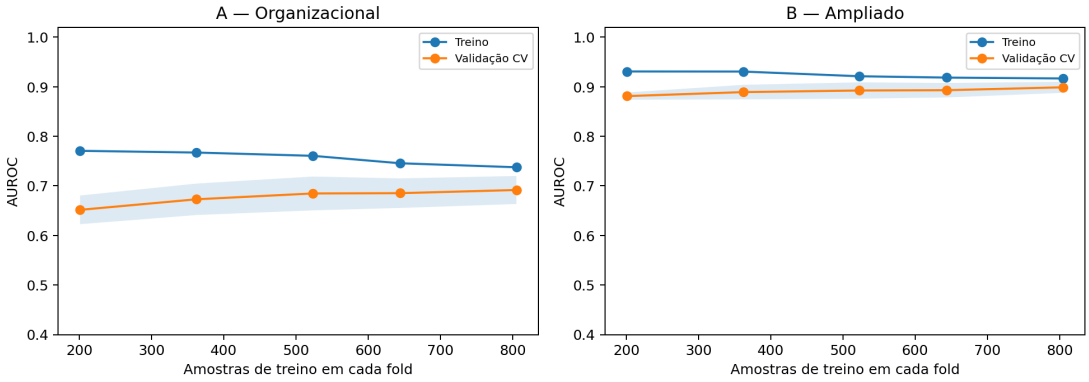


Figura 4: Curvas de aprendizado dos modelos selecionados, calculadas no treinamento por validação cruzada.

Fonte: elaboração própria.

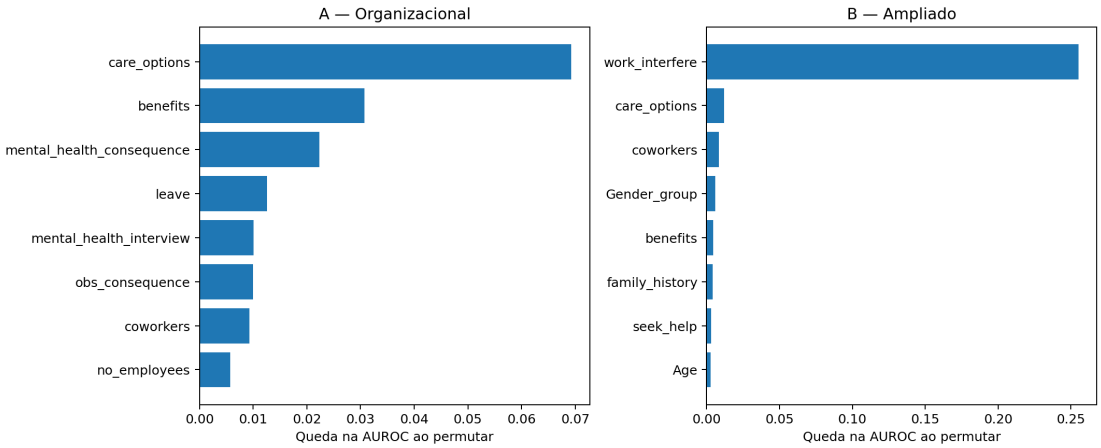


Figura 5: Importância por permutação, medida como queda média na AUROC ao perturbar cada coluna original.

Fonte: elaboração própria; análise exploratória no conjunto de teste.

5 Discussão

O modelo organizacional apresentou discriminação superior ao acaso, mas moderada. As respostas sobre serviços, suporte e atitudes no trabalho contêm informação sobre o histórico autorrelatado de tratamento entre participantes da OSMI 2014. Não se pode interpretar essa relação como evidência de que determinado benefício cause maior demanda clínica ou de que a retirada de um benefício reduza transtornos. A ausência de definição temporal torna plausível

também a direção inversa: ter buscado tratamento pode alterar o conhecimento e a percepção do respondente sobre recursos disponíveis.

O resultado central é metodológico: a AUROC próxima de 0,90 obtida no conjunto ampliado seria enganosa se reportada isoladamente. A variável `work_interfere` pergunta sobre interferência percebida de uma condição mental no trabalho e contém um padrão de ausência quase determinístico da classe negativa. A ablação revela que o resultado elevado está ligado a um sinal informativo que não pertence propriamente ao ambiente organizacional. A literatura sobre estigma e divulgação no trabalho apoia a relevância do tema, mas não valida essa variável como marcador clínico ou de decisão de RH (MCGRATH et al., 2023; TOTH et al., 2023).

Entre as limitações, destacam-se a amostragem não probabilística, o predomínio geográfico dos EUA, a coleta em 2014, a falta de identificador para verificar respostas duplicadas, a dependência de autorrelato, o agrupamento redutor de categorias de gênero, os campos condicionais e a ausência de confirmação clínica. O hold-out é interno à mesma fonte, e os intervalos bootstrap não incluem incerteza de seleção e treinamento de modelos. As métricas não indicam calibração clínica, utilidade prospectiva ou desempenho na população geral de profissionais de tecnologia. A existência de risco de estigmatização e discriminação torna inadequada sua aplicação à classificação individual de trabalhadores.

Como trabalhos futuros, recomenda-se validação temporal e externa com questionários comparáveis, investigação da robustez sem atributos potencialmente posteriores ao desfecho, análise de subgrupos com tamanho adequado, comparação de calibração e eventual formulação prospectiva com definição explícita do momento da previsão. Para RH, uma aplicação menos arriscada seria análise agregada e voluntária de conhecimento sobre benefícios e barreiras organizacionais, sem identificar ou pontuar pessoas.

6 Conclusão

O estudo implementou e avaliou de forma reprodutível três algoritmos em dois cenários de atributos. Com respostas organizacionais, a regressão logística selecionada por validação cruzada alcançou AUROC 0,698; com atributos individuais, AUROC 0,898. Entretanto, a sensibilidade à exclusão de `work_interfere` evidenciou a dependência de um preditor condicional e próximo ao histórico de tratamento, cuja presença pode distorcer a interpretação do ganho. Assim, o principal resultado científico do projeto não é a maior métrica isolada, mas a identificação das condições e limitações sob as quais ela foi produzida. A análise responde à pergunta de classificação retrospectiva na amostra observada, não estabelece causalidade e não sustenta uso clínico ou decisão individual sobre empregados.

Referências

BREIMAN, L. Random forests. *Machine Learning*, v. 45, n. 1, p. 5–32, 2001. Disponível em: <https://doi.org/10.1023/A:1010933404324>.

COLLINS, G. S. et al. TRIPOD+AI statement: updated guidance for reporting clinical prediction models that use regression or machine learning methods. *BMJ*, v. 385, p. e078378, 2024. Disponível em: <https://doi.org/10.1136/bmj-2023-078378>.

FAWCETT, T. An introduction to ROC analysis. *Pattern Recognition Letters*, v. 27, n. 8, p. 861–874, 2006. Disponível em: <https://doi.org/10.1016/j.patrec.2005.10.010>.

MCGRATH, M. O. et al. Disclosure of mental health problems or suicidality at work: A systematic review. *International Journal of Environmental Research and Public Health*, v. 20, n. 8, p. 5548, 2023. Disponível em: <https://doi.org/10.3390/ijerph20085548>.

Open Sourcing Mental Illness. *Mental Health in Tech Survey, 2014: dataset and questionnaire*. 2014. Conjunto de dados de pesquisa voluntaria, consultado em 2026. Disponível em: <https://www.kaggle.com/datasets/osmi/mental-health-in-tech-survey>.

Open Sourcing Mental Illness. *Research: Mental Health in Tech Surveys*. 2026. Historico de pesquisas e dados publicos, acesso em novembro de 2026. Disponível em: <https://www.osmihelp.org/research.html>.

PEDREGOSA, F. et al. Scikit-learn: Machine learning in python. *Journal of Machine Learning Research*, v. 12, p. 2825–2830, 2011. Disponível em: <https://jmlr.org/papers/v12/pedregosa11a.html>.

TOTH, M. D. et al. Evidence for the effectiveness of interventions to reduce mental health related stigma in the workplace: a systematic review. *BMJ Open*, v. 13, n. 2, p. e067126, 2023. Disponível em: <https://doi.org/10.1136/bmjopen-2022-067126>.